

Тема 1. Основные определения и задачи математической статистики.

1. Основные задачи математической статистики.

Математическая статистика – это раздел математики, в котором рассматриваются задачи восстановления «вероятностной структуры» исследуемых объектов, явлений или процессов на основе ряда наблюдений над этими объектами, явлениями или процессами.

Пусть, например, имеется монета с неизвестной вероятностью выпадения герба p . В данном случае вероятность p определяет «вероятностную структуру» монеты. Представим, что с данной монетой выполняется эксперимент, который заключается в том, что монета подбрасывается 100 раз и по результатам бросаний подсчитывается количество выпавших гербов. Предположим, что при выполнении эксперимента герб выпал 74 раза. Что можно сказать о монете и неизвестной вероятности p ? Из проведенного над монетой наблюдения следует, что монета, скорее всего, не является симметричной, а неизвестная вероятность p больше, чем 0.5. Сделанные выводы являются интуитивными и неформальными, в то время как математическая статистика располагает формальными и эффективными методами решения целого ряда практических задач в достаточно общей постановке.

Применительно к рассматриваемому примеру с монетой методы математической статистики позволяют решить следующие основные задачи:

1) построить оценку (найти метод приближенного вычисления) неизвестной вероятности p (задача построения точечной оценки);

2) построить интервал (p_1, p_2) , в котором с большой вероятностью находится вероятность p (задача построения доверительного интервала);

3) определить можно ли с большой долей уверенности считать, что монета является симметричной, то есть, считать, что вероятность $p = 0.5$ (задача проверки статистической гипотезы);

4) определить какое из двух утверждений « $p = 0.5$ » либо « $p = 0.7$ » является «более правдоподобным» (задача различения двух простых гипотез).

2. Основные определения.

В задачах математической статистики основу исходных данных образует серия наблюдений, которая в простых задачах может иметь вид вектора или последовательности случайных величин:

$$\xi_1(\omega), \xi_2(\omega), \dots, \xi_n(\omega), \dots$$

где ω – элементарное событие (исход) из множества всех элементарных событий Ω .

В наиболее простых и хорошо изученных задачах серия наблюдений представляет собой выборку [Боровков].

Определение 1.1.

Выборкой называется вектор случайных величин (ξ_1, \dots, ξ_n) , в котором:

- 1) все случайные величины ξ_1, \dots, ξ_n независимы в совокупности,
- 2) все случайные величины ξ_1, \dots, ξ_n имеют одинаковую функцию распределения.

Если функция распределения $F_\xi(x)$, участвующая в определении выборки, известна (либо известен параметрический вид функции распределения $F_\xi(x|\theta)$), то коротко говорят « (ξ_1, \dots, ξ_n) – выборка из распределения $F_\xi(x)$ ». Поскольку всякая функция распределения $F_\xi(x)$ задает некоторую случайную величину ξ , то иногда говорят « (ξ_1, \dots, ξ_n) – выборка из распределения случайной величины ξ ».

Определение 1.2.

Число n в определении выборки 1.1 называется *объемом выборки*.

Проведение статистического эксперимента фактически эквивалентно фиксированию некоторого элементарного события $\omega^* \in \Omega$ из множества всех элементарных событий Ω . Формально, каждая случайная величина ξ_i выборки является функцией $\xi_i(\omega)$ определенной на множестве элементарных исходов Ω , поэтому при фиксированном ω^* случайные величины $\xi_1(\omega), \dots, \xi_n(\omega)$ выборки принимают определенные числовые значения $x_i = \xi_i(\omega^*)$ ($i = \overline{1, n}$).

Определение 1.3.

Реализациями выборки называются числовые векторы (x_1, \dots, x_n) , такие что:

$$(x_1, x_2, \dots, x_n) = (\xi_1(\omega^*), \xi_2(\omega^*), \dots, \xi_n(\omega^*)),$$

для некоторого $\omega^* \in \Omega$.

С каждой выборкой непосредственно связаны две основных характеристики: вариационный ряд и эмпирическая функция распределения.

Рассмотрим определение вариационного ряда. Представим, что проведен эксперимент, в результате которого реализовалось элементарное событие $\omega^* \in \Omega$ и функции $\xi_1(\omega), \dots, \xi_n(\omega)$ приняли определенные числовые значения x_1, \dots, x_n :

$$x_i = \xi_i(\omega^*), i = \overline{1, n}.$$

Числа x_1, \dots, x_n могут быть упорядочены по возрастанию следующим образом: сперва найдем наименьшее из всех чисел x_1, \dots, x_n и обозначим его $x_{(1)}$. Затем найденное число $x_{(1)}$ исключим из множества всех чисел x_1, \dots, x_n , найдем наименьшее из оставшихся чисел $x_1, \dots, x_n \setminus \{x_{(1)}\}$ и обозначим его $x_{(2)}$. Далее аналогичным образом продолжим процедуру упорядочивания и нахождения чисел $x_{(i)}$ до тех пор, пока не будет найдено число $x_{(n)}$, являющееся наибольшим из всех чисел x_1, \dots, x_n . Заметим, что подобная процедура упорядочивания и нахождения чисел $x_{(1)}, \dots, x_{(n)}$ может быть проделана при каждом фиксированном ω^* . Таким образом, при каждом $\omega \in \Omega$ однозначно определены все числа $x_{(1)}, \dots, x_{(n)}$ и имеет смысл определение функций $\xi_{(1)}(\omega), \dots, \xi_{(n)}(\omega)$ таких, что каждая функция $\xi_{(i)}$ при фиксированном ω равна числовому значению $x_{(i)}$, полученному в процессе упорядочивания чисел x_1, \dots, x_n :

$$\xi_{(i)}(\omega) = x_{(i)}, i = \overline{1, n}.$$

Определение 1.4.

Вариационным рядом выборки $\xi = (\xi_1, \dots, \xi_n)$ называется упорядоченная совокупность случайных величин $\xi_{(1)}, \xi_{(2)}, \dots, \xi_{(n)}$:

$$\xi_{(1)} \leq \xi_{(2)} \leq \dots \leq \xi_{(n)},$$

в которой $\xi_{(1)}$ принимает наименьшее значение из ξ_1, \dots, ξ_n , $\xi_{(2)}$ — значение следующее по величине за $\xi_{(1)}$, и так далее, а $\xi_{(n)}$ — наибольшее из значений ξ_1, \dots, ξ_n .

Определение 1.5.

Случайные величины $\xi_{(1)}, \dots, \xi_{(n)}$ вариационного ряда называются *порядковыми статистиками*. Случайная величина $\xi_{(k)}$ называется *k-ой порядковой статистикой*. Случайные величины $\xi_{(1)}$ и $\xi_{(n)}$ называются *экстремальными значениями выборки*.

Фактически, простое аналитическое выражение имеют только экстремальные значения выборки:

$$\xi_{(1)} = \min\{\xi_1, \dots, \xi_n\}, \xi_{(n)} = \max\{\xi_1, \dots, \xi_n\}.$$

Рассмотрим определение эмпирической функции распределения. Согласно определению выборки (определение 1.1) все случайные величины выборки ξ_i имеют одинаковую функцию распределения, которую обозначим $F_\xi(x)$. Функция $F_\xi(x)$ играет очень важную роль при решении многих задач, поскольку полностью определяет совместное распределение величин выборки (ξ_1, \dots, ξ_n) . Однако функция распределения $F_\xi(x)$ в большинстве задач либо неизвестна, либо известна с точностью до параметра (известен параметрический вид функции распределения $F_\xi(x)$). Отсюда происходит вполне естественное стремление на основе имеющейся выборки (ξ_1, \dots, ξ_n) для неизвестной функции $F_\xi(x)$ построить известное «приближение», которое затем использовать при решении задач. Таким «приближением» в математической статистике является эмпирическая функция распределения $F_n^*(x; \xi_1, \dots, \xi_n)$.

Пусть вектор $(\xi_1(\omega), \dots, \xi_n(\omega))$ является выборкой, определим случайную функцию $\mu_n(x; \xi_1, \dots, \xi_n)$ так, что при фиксированных x и ω функция $\mu_n(x; \xi_1, \dots, \xi_n)$ равна количеству значений из $\xi_1(\omega), \dots, \xi_n(\omega)$ меньших x :

$$\mu_n(x; \xi_1, \dots, \xi_n) = |\{j : \xi_j(\omega) < x\}|.$$

Заметим, что при каждом фиксированном x величина $\mu_n(x; \xi_1, \dots, \xi_n)$ является случайной, поскольку сами величины $\xi_1(\omega), \dots, \xi_n(\omega)$ являются случайными и, следовательно, количество тех значений среди них, которые окажутся меньше x , также случайно.

Определение 1.6.

Эмпирической функцией распределения называется случайная функция $F_n^*(x; \xi_1, \dots, \xi_n)$:

$$F_n^*(x; \xi_1, \dots, \xi_n) = \frac{\mu_n(x; \xi_1, \dots, \xi_n)}{n},$$

где функция $\mu_n(x; \xi_1, \dots, \xi_n)$ равна количеству случайных величин выборки $(\xi_1(\omega), \dots, \xi_n(\omega))$ меньших x .

Представление о том насколько «хорошим» приближением к функции $F_\xi(x)$ является эмпирическая функция распределения $F_n^*(x; \xi_1, \dots, \xi_n)$ дают следующие теоремы.

Теорема (сходимость по вероятности)

Пусть $F_n^*(x; \xi_1, \dots, \xi_n)$ является эмпирической функцией распределения, построенной по выборке (ξ_1, \dots, ξ_n) из распределения $F_\xi(x)$, тогда при всяком фиксированном x^* случайная величина $F_n^*(x^*; \xi_1, \dots, \xi_n)$ сходится по вероятности к $F_\xi(x^*)$ при $n \rightarrow \infty$:

$$F_n^*(x^*; \xi_1, \dots, \xi_n) \xrightarrow{P} F_\xi(x^*), \text{ при } n \rightarrow \infty.$$

Теорема (равномерная сходимость по вероятности)

Пусть $F_n^*(x; \xi_1, \dots, \xi_n)$ является эмпирической функцией распределения, построенной по выборке (ξ_1, \dots, ξ_n) из распределения $F_\xi(x)$, тогда последовательность случайных величин $\sup_{-\infty < x < \infty} |F_n^*(x; \xi_1, \dots, \xi_n) - F_\xi(x)|$ сходится к нулю по вероятности при $n \rightarrow \infty$:

$$\sup_{-\infty < x < \infty} |F_n^*(x; \xi_1, \dots, \xi_n) - F_\xi(x)| \xrightarrow{P} 0, \text{ при } n \rightarrow \infty.$$

Теорема (Гливленко, сходимость с вероятностью 1)

Пусть $F_n^*(x; \xi_1, \dots, \xi_n)$ является эмпирической функцией распределения, построенной по выборке (ξ_1, \dots, ξ_n) из распределения $F_\xi(x)$, тогда последовательность случайных величин

$\sup_{-\infty < x < \infty} |F_n^*(x; \xi_1, \dots, \xi_n) - F_\xi(x)|$ сходится к нулю с вероятностью 1 («почти наверное») при $n \rightarrow \infty$:

$$\sup_{-\infty < x < \infty} |F_n^*(x; \xi_1, \dots, \xi_n) - F_\xi(x)| \xrightarrow{p.H.} 0, \text{ при } n \rightarrow \infty.$$

На практике в результате проведения эксперимента будет получен вектор числовых значений (x_1, \dots, x_n) (в результате проведения эксперимента происходит элементарное событие ω^* , так что все случайные величины выборки $\xi_i(\omega)$ принимают определенные числовые значения $x_i = \xi_i(\omega^*)$). Функция $\mu_n(x; x_1, \dots, x_n)$ оказывается равной количеству числовых значений в векторе (x_1, \dots, x_n) меньших заданного x , а эмпирическая функция распределения $F_n^*(x; x_1, \dots, x_n)$ равна количеству значений меньших x , отнесенному к общему количеству числовых значений n . Типичный график реализации функции $F_n^*(x; x_1, \dots, x_n)$ как функции переменной x , представлен на рисунке 1.1.




Рисунок 1.1. График реализации эмпирической функции распределения $F_n^*(x; x_1, \dots, x_n)$ как функции x .